

Universidad de Sonora

Doctorado en Ciencias Económicas y Administrativas

Procesamiento y análisis de datos

Muestreo y distribuciones muestrales

Cómo treinta personas pueden hablar por dos mil quinientas, y cómo saber con cuánto error lo hacen.

Dr. Sergio Ramón Rossetti López

Presenta: **Luis Antonio Alonso Reyna**

Septiembre 2026

Navega con   · Bloques con  · Tema con  · Pantalla completa con 

Qué vamos a hacer hoy

BLOQUE	CONTENIDO	MIN
1	Muestreo aleatorio simple	15
2	Introducción a las distribuciones muestrales	15
3	Distribución muestral de $\bar{x}$ y de $\bar{p}$	25
4	Propiedades de los estimadores puntuales	10
5	Otros métodos de muestreo	15
6	Ejercicios en SPSS: ESCUELAS en clase, HOGARES de tarea	20
7	Aplicación en investigación: un artículo	12

El problema que ordena la sesión

Casi nunca podemos medir a toda la población. Medimos una muestra y con ella **estimamos**. La pregunta de fondo es una sola: **¿qué tan lejos puede quedar mi estimación del valor verdadero, y con qué probabilidad?**

Lo que hace falta para responderla

Saber cómo se seleccionó la muestra, y conocer cómo se comporta el estadístico cuando el muestreo se repite: su **distribución muestral**. Sin eso no hay margen de error, ni nivel de confianza, ni prueba de hipótesis. Todo lo que viene en el curso descansa sobre este capítulo.

El problema de Electronics Associates

El director de personal de Electronics Associates, Inc. (EAI) tiene que responder dos preguntas sobre los **2 500 gerentes** de la empresa: cuál es su **salario anual promedio** y qué **proporción** completó el programa de capacitación gerencial.

Con el archivo de personal completo, las respuestas son exactas. Son los **parámetros** de la población:

2 500

gerentes · tamaño de la población N

\$51 800

salario medio anual · μ

\$4 000

desviación estándar · σ

0.60

proporción capacitada · p (1 500 de 2 500)

Pero ¿y si los expedientes tardaran semanas en revisarse, o si la población fueran 250 000 personas? El capítulo trabaja con EAI porque **conocemos los parámetros**: así podemos ver qué tan bien los adivina una muestra de 30.

Anderson, Sweeney y Williams · capítulo 7, sección 7.1

Vocabulario que va a aparecer todo el día

- **Población**: el conjunto completo de elementos que interesa. Los 2 500 gerentes.
- **Muestra**: un subconjunto de la población. Los 30 que vamos a seleccionar.
- **Parámetro**: característica numérica de la población: μ , σ , p . Fijo, normalmente desconocido.
- **Estadístico**: característica numérica de la muestra: $\bar{x}$, s , $\bar{p}$. Cambia de muestra a muestra.

Por qué muestrear

Tiempo y costo, sobre todo. Pero también porque a veces medir **destruye** el elemento (probar la vida útil de un foco) o porque la población no tiene fin (los clientes que seguirán llegando mañana).

Primero hay que saber qué población tenemos

El procedimiento de selección cambia según si la población se puede **enumerar** o no. Es la primera decisión, antes de abrir cualquier software.

Población finita

Tiene un número definido de elementos y, en la práctica, existe una **lista** con todos ellos: el *marco muestral*.

- Los 2 500 gerentes de EAI, en el archivo de personal.
- Los alumnos inscritos este semestre. Las empresas de un padrón. Los hogares de una colonia censada.
- Se selecciona con **muestreo aleatorio simple**, usando números aleatorios sobre la lista.

Población infinita

Los elementos se generan por un **proceso en curso** y no es posible listarlos todos.

- Los clientes que llegan a un restaurante McDonald's. Las piezas que salen de una línea de producción. Las transacciones de una tienda en línea.
- No se pueden enumerar todas las muestras posibles, así que se define una **muestra aleatoria** con dos condiciones que veremos en unas láminas.

Con reemplazo y sin reemplazo

Al seleccionar de una población finita se puede devolver cada elemento a la lista (con reemplazo, un elemento puede salir dos veces) o no devolverlo (sin reemplazo). Ambas formas son válidas, pero el muestreo aleatorio simple **se hace sin reemplazo**, y ese es el que usan las fórmulas del capítulo.

Muestra aleatoria simple: la definición y cuántas hay

Una muestra aleatoria simple de tamaño n de una población finita de tamaño N es una muestra seleccionada de manera que **cada muestra posible de tamaño n tenga la misma probabilidad** de ser seleccionada.

Anderson, Sweeney y Williams · sección 7.2

La definición no habla de elementos, habla de **muestras**. Y como cada elemento se selecciona sin reemplazo, el número de muestras distintas es el número de combinaciones:

$$\frac{N!}{n! (N - n)!}$$

muestras posibles, cada una con probabilidad 1 entre ese número

Cómo se selecciona en la práctica

Se numera la lista, se generan números aleatorios y se toman los elementos cuyos números aparecen, descartando los que caen fuera del rango y los repetidos. Es exactamente lo que hace **Datos > Seleccionar casos > Muestra aleatoria de casos** en SPSS.

Calcula cuántas muestras existen

Población N

Muestra n

2500

30

EAI: 2 500 y 30

5 elementos y 2

100 y 10

2.75×10^{69}

muestras posibles de 30 elementos tomadas de 2 500

Cada muestra tiene probabilidad 1 entre 2.75×10^{69} . Cada elemento tiene probabilidad $n/N = 30/2\,500 = 0.012$ de ser incluido.

Lo que significa ese número

Para EAI hay del orden de 10^{69} muestras posibles de 30 gerentes. La muestra que tomamos es *una* de ellas, elegida con la misma probabilidad que cualquier otra. Esa es la garantía que después permite calcular probabilidades sobre $\bar{x}$.

Cinco elementos, muestras de dos

Una población finita tiene cinco elementos: A, B, C, D, E . Queremos muestras aleatorias simples de tamaño 2.

1. Enumera las muestras posibles. $5! / (2! \cdot 3!) = 10$:

A, B 1/10	A, C 1/10	A, D 1/10	A, E 1/10	B, C 1/10
B, D 1/10	B, E 1/10	C, D 1/10	C, E 1/10	D, E 1/10

2. ¿Cuál es la probabilidad de cada una? Por definición, todas la misma: **1/10**.
Observa que cada elemento aparece en 4 de las 10 muestras, así que cada elemento tiene probabilidad $4/10 = 2/5$ de ser incluido: igual a n/N .

Anderson, capítulo 7, ejercicio 3 · Resultado: la muestra queda formada por **E** y **C**

3. Selecciona una muestra con números aleatorios

El número 1 corresponde a A , el 2 a B , y así hasta el 5 para E . Lee estos dígitos de izquierda a derecha:

8

0

5

7

5

3

2

Muestra:

Pulsa **Siguiente dígito** para ir leyendo.

Siguiente dígito

Reiniciar

Las dos reglas del procedimiento

Un dígito fuera del rango (aquí 0, 6, 7, 8 y 9) **se descarta**. Un dígito que repite un elemento ya seleccionado **también**, porque el muestreo es sin reemplazo. Se detiene cuando la muestra tiene n elementos.

Cuando no hay lista: la población infinita

McDonald's quiere estimar el perfil de sus clientes. La población son **todos los clientes que llegan**: los de hoy, los de mañana, los que seguirán llegando. No hay lista, no hay N y no se pueden enumerar todas las muestras posibles.

Para ese caso el capítulo define la **muestra aleatoria** (ya no «simple») con dos condiciones:

1. Misma población

Cada elemento seleccionado proviene de **la misma población**. Los clientes del sábado por la noche y los del martes a mediodía son clientes de McDonald's, pero muestrear sólo a la hora de la comida deja fuera una parte del proceso.

2. Independencia

Cada elemento se selecciona **de forma independiente**. Entrevistar a un cliente y luego a sus tres acompañantes viola la condición: sus respuestas se parecen entre sí más que las de la población.

Dónde aparece en investigación

- Piezas que salen de una **línea de producción**: se muestrea el proceso, no un lote cerrado.
- Llamadas a un centro de atención, visitas a un sitio web, transacciones con tarjeta.
- Encuestas a **transeúntes** o usuarios de un servicio, cuando no hay padrón.

La trampa habitual

Como no hay lista, es fácil «muestrear» lo que está a la mano y llamarlo aleatorio. Las dos condiciones son el criterio para saber si una muestra de un proceso puede tratarse como aleatoria; si no se cumplen, las fórmulas de las siguientes láminas **no aplican**.

Lo que la muestra dice de la población

Seleccionamos una muestra aleatoria simple de **30 gerentes** de EAI y calculamos sus estadísticos. Cada uno es el **estimador puntual** del parámetro correspondiente:

PARÁMETRO POBLACIONAL	VALOR	ESTIMADOR PUNTUAL	ESTIMACIÓN
Media μ del salario anual	\$51 800	$\bar{x}$ media muestral	\$51 814
Desviación estándar σ	\$4 000	s desviación estándar muestral	\$3 348
Proporción p capacitada	0.60	$\bar{p}$ proporción muestral	0.63

Las estimaciones no coinciden con los parámetros, pero se acercan. La diferencia, por ejemplo $\$51\,814 - \$51\,800 = \textbf{\$14}$, no es un error de cálculo: es la consecuencia inevitable de haber medido 30 personas y no 2 500. Se llama **error muestral** y es el protagonista del resto de la sesión.


Población muestreada y población objetivo

La **población muestreada** es aquella de la que realmente se extrajo la muestra (los gerentes en el archivo de EAI). La **población objetivo** es sobre la que se quiere concluir. Deben ser la misma. Si el marco tiene huecos, la inferencia se aplica al marco, no a la población que interesa.

La idea que se lleva del bloque

Una muestra sirve para estimar sólo si **sabemos cómo se seleccionó**. La aleatoriedad no es un adorno metodológico: es lo que permite, en el bloque 3, calcular la probabilidad de que $\bar{x}$ quede cerca de μ .

¿Qué pasa si repetimos la muestra?



Valores ilustrativos. La empacadora envasa miles de cajas; el gerente pesa 50 por día.

Tres muestras, tres promedios distintos: eso es el error muestral

El gerente de calidad de una empacadora de uva toma una muestra de **50 cajas** cada día durante tres días y calcula el peso medio: obtiene $\bar{x}_1$, $\bar{x}_2$ y $\bar{x}_3$. Como cada muestra contiene cajas distintas, **los tres promedios son distintos**, aunque el proceso no cambió.

La consecuencia

$\bar{x}$ no es un número fijo: es una **variable aleatoria**. Su valor depende de qué muestra salió. Y toda variable aleatoria tiene una distribución de probabilidad.

Definición

La **distribución muestral** de un estadístico es la distribución de probabilidad de **todos los valores posibles** que ese estadístico puede tomar al repetir el muestreo. Hay una para $\bar{x}$, otra para $\bar{p}$, otra para s .

Quinientas muestras de treinta gerentes


Anderson repite el experimento de EAI: selecciona **500 muestras aleatorias simples** de 30 gerentes cada una y anota las 500 medias muestrales. Agrupadas en clases de \$500:

MEDIA MUESTRAL ($\bar{x}$)	FRECUENCIA	FRECUENCIA RELATIVA
\$49 500 – \$49 999	2	0.004
\$50 000 – \$50 499	16	0.032
\$50 500 – \$50 999	52	0.104
\$51 000 – \$51 499	101	0.202
\$51 500 – \$51 999	133	0.266
\$52 000 – \$52 499	110	0.220
\$52 500 – \$52 999	54	0.108
\$53 000 – \$53 499	26	0.052
\$53 500 – \$53 999	6	0.012
Total	500	1.000

Anderson, sección 7.4 · Distribución de frecuencia de $\bar{x}$ en 500 muestras aleatorias simples de 30 gerentes de EAI

Distribución de las 500 medias muestrales

n = 30 gerentes por muestra · clases de \$500



Cómo se lee

La mayoría de las medias muestrales (**344 de 500, el 69 %**) cayó entre \$51 000 y \$52 499, alrededor de $\mu = \$51\,800$. Ninguna quedó por debajo de \$49 500 ni por encima de \$54 000. La forma es aproximadamente de campana. Esa figura es la distribución muestral de $\bar{x}$, estimada con 500 repeticiones.

Hagámoslo nosotros: 500 muestras, el tamaño que quieras

Tamaño de muestra n


30

Volver a muestrear

☒ Curva normal teórica

500 medias muestrales con $n = 30$

población simulada: $\mu = 51\,800$, $\sigma = 4\,000$



\$51 814

media de las 500 $\bar{x}$

\$691.7

desv. estándar de las 500 $\bar{x}$

\$730.3

teórica: $\sigma / \sqrt{n}$

\$49 603 – \$53 827

mínimo y máximo

Qué observar

- La media de las 500 $\bar{x}$ queda **cerca de \$51 800** sin importar n .
- La dispersión de las $\bar{x}$ **se encoge** al crecer n , y coincide con $\sigma/\sqrt{n}$.
- Pulsa «Volver a muestrear»: el histograma cambia, la forma no.

Nota

Población simulada con $\mu = 51\,800$ y $\sigma = 4\,000$. En el bloque 3 veremos que estos tres hechos no son casualidad: tienen fórmula.

Tres cosas que describen una distribución muestral

El centro

El punto más alto de la distribución de $\bar{x}$ se alinea con el promedio real de la población, μ . Las medias muestrales no se sesgan sistemáticamente hacia arriba ni hacia abajo.

La forma

Con muestras suficientemente grandes, la distribución de $\bar{x}$ toma forma de **campana** aunque la población no la tenga. Ese resultado tiene nombre: teorema del límite central.

La dispersión

La gran mayoría de las medias muestrales cae **cerca** de μ , y qué tan cerca depende de σ y de n . Esa dispersión es el **error estándar**.

Por qué importa

La distribución muestral es lo que nos dice qué tan cerca o qué tan lejos se espera que esté $\bar{x}$ de μ . Sin ella no podríamos calcular márgenes de error ni niveles de confianza: la estimación sería un número sin garantía. El bloque 3 pone fórmulas a las tres cosas.

El centro: valor esperado de $\bar{x}$

Si pudiéramos tomar *todas* las muestras posibles y promediar sus medias, ¿qué obtendríamos? Exactamente la media de la población:

$$E(\bar{x}) = \mu \text{ para muestreo aleatorio simple}$$


Para EAI, $E(\bar{x}) = \$51\,800$. Es lo que vimos en la simulación: la media de las 500 medias rondaba ese valor con cualquier n .

Vocabulario

Cuando el valor esperado de un estimador es igual al parámetro que estima, el estimador es **insesgado**. $\bar{x}$ es un estimador insesgado de μ . Volveremos sobre esto en el bloque 4.

Distribución muestral de $\bar{x}$ para $n = 30$

la campana se centra en la media de la población



Lo que no dice el resultado

Que $E(\bar{x}) = \mu$ no significa que *nuestra* $\bar{x}$ valga μ . Significa que el procedimiento no tiene una tendencia sistemática a errar en una dirección. Una muestra concreta puede quedar arriba o abajo; en promedio, acierta.

La dispersión: desviación estándar de $\bar{x}$

Población infinita

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

También cuando la población es finita pero $n/N \leq 0.05$.

Población finita

$$\sigma_{\bar{x}} = \sqrt{\frac{N-n}{N-1}} \frac{\sigma}{\sqrt{n}}$$

El primer factor es la **corrección por población finita**. Sólo pesa cuando la muestra es una fracción grande de la población.


EAI

$n/N = 30/2\,500 = 0.012$, muy por debajo de 0.05, así que se usa la fórmula simple: $\sigma_{\bar{x}} = 4\,000 / \sqrt{30} = \textbf{\$730.3}$. Con la corrección daría \$726.1: la diferencia no justifica el trabajo.

A la desviación estándar de un estimador puntual se le llama **error estándar**. Es la unidad con la que se mide qué tan lejos «suele» quedar la estimación del parámetro.

Error estándar de $\bar{x}$ según el tamaño de muestra

$\sigma = 4\,000$ · población infinita



Cómo se lee

El error estándar cae con la **raíz** de n , no con n . Pasar de 30 a 100 gerentes lo reduce de \$730 a \$400; para bajarlo a \$200 harían falta 400 gerentes. Cada mejora cuesta cuatro veces más que la anterior.

La forma: dos casos

Caso 1 · La población tiene distribución normal

Entonces la distribución muestral de $\bar{x}$ es **normal para cualquier tamaño de muestra**, incluso $n = 2$. No hay nada que esperar ni que verificar.

Caso 2 · La población no es normal (o no sabemos)

Aquí entra el **teorema del límite central**: al seleccionar muestras aleatorias simples de tamaño n de una población, la distribución muestral de $\bar{x}$ se aproxima a una distribución normal **a medida que el tamaño de la muestra se hace grande**.

¿Qué tan grande es «grande»?

La práctica estadística usa **$n \geq 30$** como regla general: con 30 observaciones la aproximación normal es buena para la mayoría de las poblaciones. Si la población es **muy sesgada** o tiene valores atípicos, puede hacer falta $n \approx 50$. Y si la población es normal, no hace falta nada.

Lo que el teorema no dice

No dice que *los datos* se vuelvan normales al tener más de 30. Un ingreso sigue siendo sesgado con $n = 10\,000$. Lo que se vuelve normal es la distribución de **la media** de esos datos. La siguiente lámina lo muestra.

Tres poblaciones que no son normales

Población:

Uniforme

Orejas de conejo

Sesgada

Tamaño n :

1

2


5

30

Repetir

Población: Uniforme

distribución de la variable x




Izquierda, la población de la que se muestrea. Derecha, la distribución de $\bar{x}$ obtenida con **3 000 muestras** de tamaño n . Con $n = 1$ la derecha es la población misma. Con $n = 2$ ya se asoma un pico. Con $n = 5$ aparece la campana. Con $n = 30$ la forma original ya no se distingue, y la campana es más **angosta**: es el efecto de $\sigma/\sqrt{n}$.

Reproduce la figura 7.3 de Anderson con datos simulados en tu navegador.

Distribución muestral de $\bar{x}$ con $n = 2$

3 000 muestras simuladas



Nota para la población sesgada

Observa que con $n = 5$ todavía se ve la cola derecha. Es el caso donde la regla de 30 se queda corta si el sesgo es fuerte.

BLOQUE 3 · VALOR PRÁCTICO DE LA DISTRIBUCIÓN MUESTRAL


¿Qué probabilidad hay de que $\bar{x}$ quede a $\pm \$500$ de μ ?

$n = 30$

$n = 100$

Distribución muestral de $\bar{x}$ con $n = 30$

error estándar $\sigma/\sqrt{n} = \$730.3$



Los pasos con la tabla normal

1. $\sigma_{\bar{x}} = 4\,000 / \sqrt{30} = \mathbf{730.3}$
2. z para 52 300: $(52\,300 - 51\,800) / 730.3 = \mathbf{0.68} \rightarrow P(z \leq 0.68) = 0.7517$
3. z para 51 300: $(51\,300 - 51\,800) / 730.3 = \mathbf{-0.68} \rightarrow P(z \leq -0.68) = 0.2483$
4. $P(51\,300 \leq \bar{x} \leq 52\,300) = 0.7517 - 0.2483 = \mathbf{0.5034}$

Cómo se lee


Con una muestra de 30 gerentes, sólo **la mitad** de las muestras posibles produce una media a \$500 o menos de la verdadera. La otra mitad yerra por más. Ese es el precio de medir 30 y no 2 500. Cambia a $n = 100$ para ver qué compra una muestra más grande.

BLOQUE 3 · LA IMPORTANCIA DEL TAMAÑO DE LA MUESTRA

Lo que compra una muestra más grande

Dos distribuciones muestrales de $\bar{x}$ con el mismo centro

misma población, distinto tamaño de muestra



0.5034

$P(51\,300 \leq \bar{x} \leq 52\,300)$
con $n = 30$

0.7888

la misma probabilidad
con $n = 100$

Qué cambió y qué no

- El **centro** no se movió: $E(\bar{x}) = \$51\,800$ en ambos casos.
- El **error estándar** bajó de \$730.3 a \$400, y la campana se estrechó.
- Por eso la misma franja de $\pm \$500$ ahora captura **79 %** de las medias muestrales en vez de 50 %.

La idea

Aumentar n no hace que $\bar{x}$ «acierta más»: hace que **yerre menos**. Es la única palanca que controla el investigador, y su costo crece más rápido que su beneficio.

La misma lógica para una proporción

La proporción muestral $\bar{p} = x/n$ también cambia de muestra a muestra, y su distribución muestral se describe con las mismas tres piezas:


PIEZA	RESULTADO	EAI ($p = 0.60, n = 30$)
Centro	$E(\bar{p}) = p$	0.60
Dispersión	$\sigma_{\bar{p}} = \sqrt{[p(1 - p) / n]}$	$\sqrt{(0.6 \times 0.4 / 30)} = \mathbf{0.0894}$
Forma	Normal si $np \geq 5$ y $n(1 - p) \geq 5$	18 y 12: se cumple

Pregunta práctica

¿Cuál es la probabilidad de que $\bar{p}$ quede a ± 0.05 de p ? $z = 0.05 / 0.0894 = 0.56 \rightarrow 0.7123 - 0.2877 = \mathbf{0.4246}$. Con 30 gerentes, sólo 42 % de las muestras dan una proporción entre 0.55 y 0.65. Para una proporción, 30 es poco.

Distribución muestral de $\bar{p}$ con $n = 30$

$p = 0.60$ · error estándar 0.0894



Cuando $n/N > 0.05$ se aplica la misma corrección por población finita que a $\sigma_{\bar{x}}$. Para EAI no hace falta.

La receta completa, en cinco pasos

1. **Identifica el parámetro** que interesa (μ o p) y el estimador que lo apunta ($\bar{x}$ o $\bar{p}$).
2. **Centro**: el valor esperado del estimador es el parámetro.
3. **Dispersión**: calcula el error estándar, $\sigma/\sqrt{n}$ o $\sqrt{[p(1-p)/n]}$, con corrección si $n/N > 0.05$.
4. **Forma**: normal si la población lo es, o si $n \geq 30$ (para $\bar{p}$: $np \geq 5$ y $n(1-p) \geq 5$).
5. **Convierte a z** y lee la probabilidad en la tabla normal.

El detalle que se olvida

Las fórmulas usan σ , la desviación estándar **de la población**. En EAI la conocemos porque el ejemplo está armado así. En investigación real casi nunca: se sustituye por s , y eso abre el capítulo siguiente, la estimación por intervalo.

La idea que se lleva del bloque

Todo margen de error que van a reportar en su tesis es, en el fondo, un múltiplo del error estándar. Y el error estándar depende de dos cosas: la variabilidad de la población, que no controlan, y el tamaño de muestra, que sí.

BLOQUE 4 · PROPIEDADES DE LOS ESTIMADORES PUNTUALES

1. Insesgadez

Un estimador es **insesgado** si su valor esperado, es decir, el promedio de todas las estimaciones posibles, es igual al parámetro que intenta estimar:

$$E(\hat{\theta}) = \theta$$


Si no se cumple, la diferencia $E(\hat{\theta}) - \theta$ es el **sesgo**: un error sistemático que ninguna muestra grande corrige, porque no viene del azar sino del procedimiento.

Lo que ya sabemos

$\bar{x}$, s^2 y $\bar{p}$ son estimadores insesgados de μ , σ^2 y p . Por eso la varianza muestral divide entre $n - 1$: dividir entre n la haría sesgada hacia abajo.

Dos estimadores del mismo parámetro θ

distribuciones muestrales



■ Estimador insesgado: centrado en θ ■ Estimador sesgado: centrado en otro lado

BLOQUE 4 · PROPIEDADES DE LOS ESTIMADORES PUNTUALES

2. Eficiencia

Entre dos estimadores **insesgados** del mismo parámetro, es más eficiente el que tiene **menor error estándar**: sus estimaciones se concentran más cerca del valor real.

El ejemplo clásico


Para una población normal, tanto la media muestral $\bar{x}$ como la mediana muestral son estimadores insesgados de μ . Pero el error estándar de la mediana es cerca de **25 % mayor** ($\approx 1.25 \sigma/\sqrt{n}$). Con la misma muestra, $\bar{x}$ es más precisa. Por eso se prefiere.

Cómo se traduce

Usar el estimador menos eficiente equivale a **tirar observaciones**: para que la mediana alcance la precisión de $\bar{x}$ con $n = 30$ se necesitarían unas 47 observaciones.

Dos estimadores insesgados de μ en una población normal

misma muestra, distinta dispersión



3. Consistencia, y las tres propiedades juntas


Un estimador es **consistente** si, a medida que el tamaño de la muestra crece, sus valores tienden a acercarse al parámetro. Es una propiedad *asintótica*: habla de lo que pasa cuando n se hace grande.

$\bar{x}$ es consistente porque su error estándar, $\sigma/\sqrt{n}$, **tiende a cero** al crecer n . Lo mismo $\bar{p}$.

PROPIEDAD	PREGUNTA QUE RESPONDE	CRITERIO
Insesgadez	¿Apunta al lugar correcto?	$E(\theta) = \theta$
Eficiencia	¿Cuál dispersa menos?	Menor error estándar entre insesgados
Consistencia	¿Mejora con más datos?	Error estándar $\rightarrow 0$ cuando $n \rightarrow \infty$

Distribución muestral de $\bar{x}$ al crecer n

$\sigma = 1$ · la campana se cierra sobre μ



La idea que se lleva del bloque

Elegir el estimador correcto es una decisión de diseño, no de software. $\bar{x}$, s y $\bar{p}$ cumplen las tres propiedades, y por eso son los que usa todo el mundo.

El muestreo aleatorio simple no es el único; sí es el patrón

Muestreo probabilístico

Cada elemento tiene una probabilidad **conocida** de ser seleccionado. Sólo con estos métodos se puede calcular el error muestral y hacer inferencia estadística.

- **Aleatorio simple:** el que vimos. Es el punto de referencia de los demás.
- **Aleatorio estratificado:** se divide la población en grupos y se muestrea dentro de cada uno.
- **Por conglomerados:** se divide en grupos y se muestrean *grupos* completos.
- **Sistemático:** se toma cada k -ésimo elemento de la lista.

Muestreo no probabilístico


La probabilidad de selección se desconoce. Son más baratos y rápidos, pero **no se puede evaluar estadísticamente** qué tan buena es la muestra.

- **De conveniencia:** se toman los elementos que están a la mano.
- **Subjetivo** (o de juicio): alguien con conocimiento del tema elige los elementos que considera representativos.

Un criterio para toda la sesión

Las fórmulas de error estándar del bloque 3 corresponden al muestreo aleatorio simple. Los otros métodos probabilísticos tienen las suyas (más complejas) y los no probabilísticos **no tienen ninguna**. Si un artículo reporta margen de error con una muestra de conveniencia, ese número no significa lo que parece.

Muestreo aleatorio estratificado



La población se divide en grupos llamados **estratos**, de modo que cada elemento pertenezca a uno y sólo uno. Después se toma una muestra aleatoria simple **de cada estrato** y los resultados se combinan con pesos según el tamaño de cada uno.

Cuándo funciona mejor

Cuando los elementos son **parecidos dentro de cada estrato** y distintos entre estratos: departamento, ubicación, grupo de edad, tamaño de empresa, sector. Con estratos homogéneos, la estimación alcanza la misma precisión que el aleatorio simple **con menos observaciones**.

Lo que aporta además

Garantiza que todos los grupos estén representados, incluso los pequeños, y permite reportar resultados **por estrato**. En el ejercicio de hogares, la colonia es el estrato.

Muestreo por conglomerados



La población se divide en grupos llamados **conglomerados**, se selecciona una muestra aleatoria simple **de conglomerados**, y se observan todos los elementos de los seleccionados (o una muestra dentro de cada uno: muestreo en dos etapas).

Cuándo funciona mejor

Cuando cada conglomerado es una **versión en pequeño de la población**: heterogéneo por dentro, parecido a los demás. Es lo contrario del estratificado. El caso típico es el **muestreo por áreas**: manzanas de una ciudad, escuelas de un estado.


El intercambio

Se gana **costo**: encuestar tres manzanas completas es mucho más barato que buscar 60 hogares dispersos por la ciudad. Se pierde precisión: para el mismo error estándar suele requerir un tamaño de muestra **mayor** que el aleatorio simple.

Muestreo sistemático

Muestra $n =$ **8**

Nuevo inicio aleatorio



Cuándo conviene

Quando la lista es muy larga y generar números aleatorios para toda ella sería lento: expedientes en un archivero, clientes en fila, facturas numeradas. Sólo se necesita un número aleatorio.

El supuesto


La lista debe estar en **orden aleatorio respecto a la variable de interés**. Si tiene un patrón periódico (por ejemplo, un jefe de área cada 10 registros), cada k -ésimo puede caer siempre en el mismo tipo de elemento.

Conveniencia y juicio: útiles, pero sin garantías



Muestreo de conveniencia

Se seleccionan los elementos que resultan **más accesibles**: un profesor que encuesta a sus propios alumnos, entrevistas en la entrada de un centro comercial, los animales que cayeron en la trampa. Es fácil de obtener; el problema es que los accesibles rara vez se parecen al resto.



Muestreo subjetivo (de juicio)

Una persona con **conocimiento del tema** elige los elementos que considera representativos: un reportero selecciona a dos o tres senadores que, a su juicio, reflejan la opinión del Senado. La calidad de la muestra depende por completo de la calidad del juicio.

Para qué sí sirven

Estudios exploratorios, pruebas piloto de un cuestionario, casos donde no existe marco muestral y el objetivo es **generar hipótesis**, no probarlas. Lo que no se puede hacer es reportar un error estándar o un intervalo de confianza como si la muestra fuera aleatoria.

Cuándo usar cuál

MÉTODO	REQUIERE	FUNCIONA MEJOR CUANDO	VENTAJA	RIESGO
Aleatorio simple	Lista completa de la población	La población es manejable y accesible	Fórmulas simples; es el patrón de referencia	Puede dejar grupos pequeños sin representar
Estratificado	Lista con la variable de estratificación	Grupos homogéneos por dentro, distintos entre sí	Más precisión con menos n ; resultados por grupo	Estratos mal definidos no aportan nada
Conglomerados	Lista de grupos, no de elementos	Cada grupo es una población en pequeño	Mucho menor costo de campo	Menor precisión; requiere n mayor
Sistemático	Lista ordenada, un solo número aleatorio	La lista es larga y no tiene ciclos	Rápido y fácil de ejecutar	Patrones periódicos en la lista
Conveniencia	Nada	Exploración, piloto	Costo mínimo	No hay inferencia posible
Subjetivo	Un experto	Casos típicos o extremos	Rápido; casos ricos en información	Depende del juicio de una persona

La idea que se lleva del bloque

El método no lo dicta el software sino tres preguntas: ¿tengo lista?, ¿la población tiene grupos que importan? y ¿cuánto cuesta llegar a cada elemento? Los ejercicios que siguen aplican tres de estos métodos a las mismas bases, precisamente para comparar qué cambia en las estimaciones.

Un ejercicio en clase y una tarea sobre las mismas ideas

Ejercicio 1 · Escuelas

EN CLASE, TODOS AL MISMO TIEMPO

Escuelas.sav: **600 escuelas** en 20 distritos. Muestreo **aleatorio simple** con $n = 235$.

Dos estimaciones puntuales: la **media de Ausentismo** ($\bar{x}$) y la **proporción de escuelas de cada Nivel** ($\bar{p}$), comparadas con la base completa.

Qué vamos a comparar

En cada esquema, la **estimación puntual** y el **error estándar** que reporta SPSS, contra el valor de la base completa. La diferencia entre la estimación y el valor completo es el error muestral en vivo; el error estándar es cuánto «debería» variar. Con las dos cosas juntas se juzga si la muestra se comportó como dice la teoría.

Ejercicio 2 · Hogares **TAREA DE LA SEMANA**

Hogares.sav: **1 000 hogares** en 25 colonias de 40. **Estratificado** por colonia y **por conglomerados** (colonias completas), de forma autónoma.

Media de Ingreso y proporción de hogares con Internet, comparadas con la base completa y entre esquemas.

Bases de datos

Descárgalas y ábrelas en SPSS **antes** de la sesión:

Escuelas .sav

Hogares .sav

Antes de muestrear: ¿de qué tamaño?

Calculadora del tamaño de la muestra

Población *N*

Nivel de confianza

Margen de error

600

95 %

5 %

235 casos para *N* = 600, confianza 95 %, margen ±5 %
*n*₀ = 384.2 para población infinita

Mismo cálculo que la calculadora de SurveyMonkey, con *p* = 0.5 (el caso más exigente). Escuelas: *N* = 600 → **235**. Hogares: *N* = 1 000 → **278**.

La fórmula viene del capítulo siguiente, pero la necesitamos hoy para decidir cuántos casos pedirle a SPSS:

$$n = \frac{n_0}{1 + n_0 / N} \quad \text{con} \quad n_0 = \frac{z^2 p(1 - p)}{e^2}$$

Cómo se lee

- n*₀ es el tamaño para una población infinita; el denominador lo corrige para una población finita de tamaño *N*.
- Bajar el margen de error de 5 % a 3 % **casi triplica** la muestra: prueba con la calculadora.
- Cuando *N* es muy grande, la corrección deja de importar: 384 casos bastan para 95 % y ±5 % en cualquier población grande.
- En nuestras bases *n*/*N* vale 0.39 y 0.28, muy por encima de 0.05: el error estándar lleva la **corrección por población finita** de la lámina 14.

POBLACIÓN <i>N</i>	100	600	1 000	3 711	100 000
<i>n</i> para 95 % y ±5 %	80	235	278	349	383

Escuelas: una muestra aleatoria simple en SPSS

SPSS **Seleccionar la muestra y describirla**

- 1. Abre Escuelas.sav ($N = 600$). Fija la semilla: Transformar > Generadores de números aleatorios... → Valor fijo 2026.
- 2. Datos > Seleccionar casos... → Muestra aleatoria de casos → botón **Ejemplo...** → Exactamente 235 casos de los primeros 600 casos.
- 3. En Salida, elige **Copiar casos seleccionados a un nuevo conjunto de datos** y nómbralo muestra_1. Aceptar. Se abre una ventana nueva con la muestra.
- 4. En muestra_1: Analizar > Estadísticos descriptivos > Frecuencias... → pasa Ausentismo y Nivel. En **Estadísticos...** marca Media, Mediana, Desv. estándar y **E.T. media**. Deja marcada *Mostrar tablas de frecuencias*: la tabla de Nivel trae la columna *Porcentaje*, que es $\bar{p}$ de cada nivel. Aceptar.
- 5. Vuelve a la base completa y repite el paso 4. Compara las dos salidas. Ignora la media de Nivel: es un código, no una cantidad.

Verifica y compara

ESTADÍSTICO	BASE COMPLETA	MUESTRA_1
Media de Ausentismo ($\mu \cdot \bar{x}$)	11.75	.
Desv. estándar de Ausentismo	4.60	.
Nivel 1 ($p \cdot \bar{p}$)	50.0 %	.
Nivel 2	30.0 %	.
Nivel 3	20.0 %	.

Error estándar teórico: $4.60/\sqrt{235} = \mathbf{0.30}$ para la media de Ausentismo y $\sqrt{(0.5 \times 0.5/235)} = \mathbf{0.033}$ (3.3 puntos) para la proporción del nivel 1; con la corrección por población finita, 0.23 y 0.025. La muestra **no** va a coincidir con la base completa; la pregunta es si la diferencia es de ese orden o mucho mayor.

Por qué la semilla

Con la misma semilla todos obtienen la misma muestra y pueden verificar entre sí. Sin ella, cada quien obtiene una distinta: no es un error, es la variabilidad muestral en vivo. Las dos cosas sirven para la sesión.

Hogares: dos esquemas sobre la misma base

SPSS Estratificado: 11 hogares de cada colonia

1. Abre Hogares.sav ($N = 1\,000$). En *Vista de variables* pon Colonia con **Medida: Nominal**.
2. **Analizar > Estadísticos descriptivos > Frecuencias...** sobre Colonia: 25 colonias de 40 hogares. Asignación proporcional: $278 \times 40/1\,000 \approx 11$ **por colonia** (275 en total).
3. Para cada colonia: **Datos > Seleccionar casos...** → *Si se satisface la condición* → Colonia = 1 → *Copiar a nuevo conjunto* Edu1.
4. En Edu1: *Muestra aleatoria* → *Exactamente 11 de los primeros 40* → nuevo conjunto m_col1. Repite para las 25 colonias.
5. Une los 25 conjuntos con **Datos > Fundir archivos > Añadir casos...** y calcula media de Ingreso y porcentaje de Internet. Como los estratos son iguales, la media simple ya es la estratificada.

SPSS Conglomerados: 7 colonias completas

1. El conglomerado es la **colonia entera** (40 hogares). Se sortean **7 de las 25**: 280 hogares, casi el mismo n . Elige las siete con dígitos aleatorios entre 01 y 25.
2. Por rango de casos: la colonia k ocupa los casos $40(k - 1) + 1$ a $40k$. **Datos > Seleccionar casos...** → *Basándose en el rango de tiempo o de casos* → **Rango...** → por ejemplo 41 a 80 para la colonia 2.
3. O en un solo paso: *Si se satisface la condición* → ANY(Colonia, 2, 5, 9, 14, 17, 21, 24) con tus siete números → nuevo conjunto muestra_conglomerados.
4. Calcula media de Ingreso y porcentaje de Internet sobre los 280 hogares.

Qué comparar al final

Valores verdaderos: $\mu = \$16\,995.6$, $\sigma = \$7\,120.7$, $p = 0.802$ con internet. Las colonias van de \$9 300 a \$25 400 de ingreso medio: estratificar **ayuda** (error estándar $\approx \$364$ contra \$427) y muestrear colonias enteras **cuesta** ($\approx \$1\,270$). Eso es lo que debe verse en la tabla.

Hogares: qué entregar

Qué hacer

1. Sobre Hogares.sav, extrae la muestra **estratificada** (11 por colonia) y la muestra **por conglomerados** (7 colonias) siguiendo la lámina anterior y las secciones 3 y 4 de la Guía de SPSS.
2. En cada una calcula la media de Ingreso, su E.T. media y el porcentaje de hogares con Internet.
3. Reúne todo en **una tabla** junto con los valores de la base completa.

Cómo se entrega

Un **solo archivo PDF**, exportado directamente del Visor de resultados de SPSS: **Archivo > Exportar...** → en *Tipo* elige **PDF**.

Con la tabla comparativa y un **párrafo breve** por esquema: qué tan lejos quedó la estimación del valor verdadero, y si esa distancia es del orden del error estándar o mucho mayor. Los párrafos se escriben en el propio Visor con **Insertar > Nuevo texto**.

Lo que se busca

No que la muestra «atine». Que el párrafo distinga **error muestral** (la diferencia que sí observaron) de **error estándar** (la diferencia que era esperable), y que use ese contraste para juzgar cada esquema.

Pista

El E.T. media que imprime SPSS en la muestra de conglomerados supone que los 280 hogares se eligieron uno por uno. No fue así: se eligieron 7 colonias. Por eso esa estimación puede quedar a \$1 000 o \$2 000 de la verdadera sin que nadie haya hecho nada mal. Explicar por qué es la parte más valiosa de la tarea.

Un artículo que muestreó como en este capítulo

Valenzo-Jiménez, M. A., & González-Samaniego, A. (2021). Capacidad de adaptación y competitividad en microempresas de abarrotes en Cuitzeo, México. *Mercados y Negocios*, (43), 49–76. <https://doi.org/10.32870/myn.v0i43.7629>
Universidad de Guadalajara · acceso abierto

La pregunta del estudio: ¿la **capacidad de adaptación** de las tiendas de abarrotes funciona como un factor de su **competitividad**? Para responderla, los autores encuestaron cara a cara a dueños y encargados de microempresas de la Región Cuitzeo, en Michoacán, entre septiembre de 2018 y marzo de 2019.

Lo que nos interesa hoy no es la conclusión sobre competitividad, sino **cómo decidieron a quién preguntarle**: es un caso de libro de población finita, tamaño de muestra y muestreo estratificado.

3 711

microempresas con más
de cinco años ·
población *N*

350

cuestionarios aplicados ·
muestra *n*

95 %

confianza · error máximo
5 %

El instrumento


29 preguntas en escala Likert de 5 puntos: 23 descriptivas (el dueño y el negocio) y 6 evaluativas (capacidad de adaptación). Procesado en SPSS 21.

Paso por paso, con los conceptos de la sesión

CONCEPTO	LO QUE HIZO EL ARTÍCULO	LÁMINA
Población finita	Microempresas de abarrotes de la región con más de 5 años: $N = 3\,711$. Un marco enumerable.	4
Tamaño de muestra	95 % de confianza y 5 % de error → 349 empresas, redondeadas a 350. Ponlo en la calculadora: sale lo mismo.	31
Estratificado	Dos estratos geográficos: Morelia (249 cuestionarios) y diez municipios de la región (101).	25
Estimación puntual	Promedios de las escalas Likert: la adopción tecnológica obtuvo 1.94 de 5, «regular».	8
Inferencia	Correlación de Spearman entre adaptación y competitividad: $\rho = 0.778$, $p < 0.01$.	20

Los 350 cuestionarios por estrato

muestreo estratificado geográfico · Región Cuitzeo, Michoacán



$n = 350$ de $N = 3\,711$ · el artículo no reporta el tamaño de cada estrato en la población

Lo que el artículo no dice

Cuántas de las 3 711 empresas hay en cada estrato (sin eso no sabemos si 249/101 es asignación proporcional) y **cómo se eligieron las tiendas dentro de cada municipio**. Si fue por conveniencia, el «error máximo del 5 %» es un cálculo previo, no una propiedad de la muestra obtenida.

Del estadístico a la conclusión

1. ¿El instrumento mide bien?

Alfa de Cronbach = **0.868**: las 29 preguntas son consistentes entre sí. Es un requisito previo: si el cuestionario no es confiable, ninguna muestra lo arregla.

2. ¿Qué forma tienen los datos?

Kolmogorov-Smirnov: la capacidad de adaptación **no** es normal ($p = 0.000$); la competitividad sí ($p = 0.200$). Por eso eligen Spearman, que no supone normalidad, en vez de Pearson.

3. ¿Hay relación?

ρ de Spearman = **0.778**, significativa al 0.01: asociación positiva fuerte. Conclusión: la adaptación es un factor de competitividad, aunque las tiendas operan en un nivel «regular».

Dónde entra lo de hoy

Ese «significativa al 0.01» es una afirmación sobre la **distribución muestral** del coeficiente: qué tan probable sería observar 0.778 en una muestra de 350 si en la población la correlación fuera cero. La probabilidad sólo tiene sentido si la muestra fue **probabilística**. Es exactamente el puente entre el bloque 3 y el bloque 5.

Para leer artículos con este lente

- Busca N , n , confianza y error: si están, el autor pensó en la distribución muestral.
- Busca cómo se eligió cada unidad. Ahí se decide si el margen de error es real.
- Busca el error estándar o intervalo junto a cada estimación. Si sólo hay medias, falta la mitad de la historia.

REFERENCIAS

Fuentes de la sesión

Texto base

Anderson, D. R., Sweeney, D. J., & Williams, T. A. (2008). *Estadística para administración y economía* (10a. ed.). Cengage Learning. ISBN-13: 978-607-481-319-7. Capítulo 7, *Muestreo y distribuciones muestrales*.

Todas las cifras del ejemplo de Electronics Associates ($N = 2\,500$, $\mu = \$51\,800$, $\sigma = \$4\,000$, $p = 0.60$; muestra de 30 con $\bar{x} = \$51\,814$, $s = \$3\,348$, $\bar{p} = 0.63$) y las probabilidades 0.5034, 0.7888 y 0.4246 provienen de ese capítulo.

Artículo de aplicación

Valenzo-Jiménez, M. A., & González-Samaniego, A. (2021). Capacidad de adaptación y competitividad en microempresas de abarrotes en Cuitzeo, México. *Mercados y Negocios*, (43), 49–76. <https://doi.org/10.32870/myn.v0i43.7629>

Herramientas

- IBM SPSS Statistics, versión 25 o superior, en español.
- Calculadora del tamaño de la muestra de [SurveyMonkey](#), replicada en la lámina 31.
- Simulaciones de las láminas 11 y 16 generadas en el navegador; no requieren conexión.

Material del editor

latinoamerica.cengage.com

MATERIALES DE LA SESIÓN

Lo que necesitas tener a la mano

Bases de datos para SPSS

Abren directo en SPSS. Escuelas: 600 escuelas, 9 variables. Hogares: 1 000 hogares, 9 variables. En Hogares, cambia la medida de Colonia a Nominal.

Escuelas .sav

Hogares .sav

Documentos

Esta presentación completa PDF

Guía de SPSS para los ejercicios PDF

Artículo Valenzo-Jiménez & González-Samaniego (2021)

acceso
abierto

Antes de la sesión

Descarga las dos bases y la guía, y confirma que abren en tu SPSS. Si algo falla, avísame **antes** de la sesión, no durante.

Muestreo y distribuciones muestrales

Pulsa cualquier bloque para volver a él. También funcionan las teclas 1 a 7.

Apertura 2 láminas · ~5 min	BLOQUE 1 Muestreo aleatorio simple 6 láminas · ~15 min 1	BLOQUE 2 Introducción a las distribuciones muestrales 4 láminas · ~15 min 2	BLOQUE 3 Distribución muestral de $\bar{x}$ y de $\bar{p}$ 8 láminas · ~25 min 3
BLOQUE 4 Propiedades de los estimadores 3 láminas · ~10 min 4	BLOQUE 5 Otros métodos de muestreo 6 láminas · ~15 min 5	BLOQUE 6 Ejercicios en SPSS 5 láminas · ~20 min 6	BLOQUE 7 Aplicación en investigación 3 láminas · ~12 min 7
Referencias, materiales e índice 3 láminas · ~3 min			